

# Wie das Automix-Modell funktioniert

Schritt-für-Schritt-Erklärung als Grundlage für das Paper

Projekt *Automatic Mixing*, Deep Learning SS26

Stand: 22. September 2026

## Zusammenfassung

Wir stellen ein kleines neuronales Netz vor, das Orchesteraufnahmen automatisch zu einem Stereomix zusammenstellt. Eingabe sind die einzelnen Mikrofonspuren einer Aufnahme – das Hauptsystem und die Stützmikrofone an den Instrumenten. Für jede Spur sagt das Modell zwei Mischpult-Einstellungen vorher: einen Pegel (Gain) und eine Position im Stereopanorama (Pan). Ein eingefrorenes, vortrainiertes Audionetz (VGGish) beschreibt den Klang jeder Spur; ein trainierbares mehrschichtiges Perzeptron mit nur 132 100 Parametern trifft daraus die Entscheidungen. Die Einstellungen werden über ein differenzierbares Pan-Gesetz zu einem Stereosignal gemischt, sodass das Modell allein aus fertigen Mischungen lernt, ohne je die „richtigen“ Reglerstellungen zu sehen. Auf zurückgehaltenen synthetischen Stücken mit bekannter Aufstellung platziert das Modell die Instrumente mit einem mittleren Fehler von  $5,8^\circ$  (Rauschgrenze  $2,5^\circ$ , Mitte-Tipp  $17,1^\circ$ ).

## Inhaltsverzeichnis

|                                                                    |          |
|--------------------------------------------------------------------|----------|
| <b>1 Die Aufgabe: Was heißt hier „automatisch mischen“?</b>        | <b>2</b> |
| <b>2 Überblick: Der Weg durch das Modell</b>                       | <b>3</b> |
| <b>3 Schritt 1: Vom Audio zum Klangvektor – der VGGish-Encoder</b> | <b>3</b> |
| <b>4 Schritt 2: Der Kontext – was spielt sonst noch mit?</b>       | <b>4</b> |
| <b>5 Schritt 3: Die Entscheidung – das MLP</b>                     | <b>4</b> |
| <b>6 Schritt 4: Anker – feste Positionen für das Hauptsystem</b>   | <b>5</b> |
| <b>7 Schritt 5: Der Mixer – ein differenzierbares Pan-Gesetz</b>   | <b>5</b> |
| <b>8 Schritt 6: Wie gut ist der Mix? – die Verlustfunktion</b>     | <b>6</b> |
| <b>9 Schritt 7: Das Training</b>                                   | <b>7</b> |
| 9.1 Daten . . . . .                                                | 7        |
| 9.2 Ablauf . . . . .                                               | 7        |
| 9.3 Experiment: Die echten Mischungen stärker gewichten . . . . .  | 7        |
| <b>10 Schritt 8: Anwendung auf ein neues Stück</b>                 | <b>8</b> |

|                                                                            |           |
|----------------------------------------------------------------------------|-----------|
| <b>11 Was das Modell kann – Ergebnisse im Überblick</b>                    | <b>9</b>  |
| <b>12 Eignen sich eigene Aufnahmen als zusätzliches Trainingsmaterial?</b> | <b>10</b> |
| 12.1 Das Konzert im Training: Der Verlust täuscht . . . . .                | 11        |
| <b>13 Grenzen und offene Punkte</b>                                        | <b>12</b> |
| <b>14 Vorschlag: Vom Dokument zum Paper</b>                                | <b>13</b> |

## 1 Die Aufgabe: Was heißt hier „automatisch mischen“?

Bei einer Orchesteraufnahme hängen viele Mikrofone gleichzeitig im Saal:

- **Hauptsystem:** wenige Mikrofone über dem Dirigenten, die das ganze Orchester als Klangbild einfangen, z. B. ein Decca-Tree aus drei Mikrofonen (links, Mitte, rechts) und oft zusätzlich ein Raum-Paar.
- **Stützmikrofone (Spots):** Mikrofone nah an einzelnen Instrumenten oder Gruppen, etwa an den ersten Violinen oder der Harfe.

Der Tonmeister mischt diese Spuren zu einem Stereosignal. Dazu stellt er für jede Spur mindestens ein, *wie laut* sie in den Mix eingeht (Gain), und *wo* sie im Stereobild erscheint (Pan). Genau diese beiden Entscheidungen soll unser Modell übernehmen.

**Formal.** Gegeben sind  $N$  Mono-Spuren  $s_1(t), \dots, s_N(t)$  eines Stücks. Gesucht ist für jede Spur ein Gain  $g_i \geq 0$  und ein Panoramawinkel  $\theta_i \in [0, \pi/2]$  (in Grad:  $0^\circ$  bis  $90^\circ$ ), sodass der daraus gemischte Stereomix

$$\hat{y}_L(t) = \sum_{i=1}^N g_i \cos(\theta_i) s_i(t), \quad \hat{y}_R(t) = \sum_{i=1}^N g_i \sin(\theta_i) s_i(t) \quad (1)$$

möglichst gut klingt – im Training heißt das: möglichst nah an einem Referenzmix  $y = (y_L, y_R)$  liegt.

**Bewusste Vereinfachung.** Das Modell wählt *eine* feste Einstellung pro Spur für das ganze Stück. Es gibt keine Pegelautomation, keinen Equalizer, keinen Hall und keine Laufzeitkorrektur. Das macht das Modell klein, die Ausgabe direkt interpretierbar (zwei Zahlen pro Spur, wie an einem Mischpult) und die ganze Kette differenzierbar. Dass die Vereinfachung nicht aus der Luft gegriffen ist, zeigen die echten Mischungen des Spheres-Datensatzes: Sie lassen sich *exakt* als Summe nach Gleichung (1) darstellen (Bestimmtheitsmaß  $R^2 = 1,000$ , Abschnitt 9).

## 2 Überblick: Der Weg durch das Modell

Abbildung 1 zeigt die gesamte Kette. Sie besteht aus vier Bausteinen, von denen *nur einer* trainiert wird:


1. **VGGish-Encoder** (eingefroren): beschreibt den Klang jeder Spur als Vektor  $e_i$ .
2. **Kontext** (keine Parameter): Mittelwert aller  $e_i$  – „was spielt in diesem Stück sonst noch mit?“
3. **MLP** (trainierbar): entscheidet aus  $e_i$  und Kontext  $c$  über Gain  $g_i$  und Pan  $\theta_i$ .

| Symbol                     | Bedeutung                                                              |
|----------------------------|------------------------------------------------------------------------|
| $N$                        | Anzahl der Spuren eines Stücks (variabel, hier 4–37)                   |
| $s_i(t)$                   | Audiosignal der Spur $i$ (mono)                                        |
| $e_i \in \mathbb{R}^{128}$ | Klang-Embedding der Spur $i$ (VGGish)                                  |
| $c \in \mathbb{R}^{128}$   | Kontextvektor: mittleres Embedding aller Spuren                        |
| $g_i \geq 0$               | Gain (linear), in dB: $20 \log_{10} g_i$                               |
| $\theta_i \in [0, \pi/2]$  | Panoramawinkel: 0 = ganz links, $\pi/4$ = Mitte, $\pi/2$ = ganz rechts |
| $m_i \in \{0, 1\}$         | Maske: 1 = echte Spur, 0 = Auffüll-Spur im Batch                       |
| $\hat{y}, y$               | vorhergesagter Stereomix, Referenzmix                                  |

**Tabelle 1:** Notation.

4. **Mixer** (keine Parameter): wendet die Einstellungen nach Gleichung (1) an und summiert zum Stereomix.

Im Training vergleicht eine Verlustfunktion den Mix mit einer Referenz; der Fehler fließt als Gradient durch den Mixer zurück in das MLP.



**Abbildung 1:** Die Pipeline. Blau: eingefroren. Violett: der einzige trainierte Baustein. Grau: feste Rechenschritte ohne Parameter. Die Rohspuren gehen zweimal ein: einmal zur Klangbeschreibung, einmal direkt in den Mixer.

**Kernaussage.** Das Modell erzeugt keinen Klang, es erzeugt Reglerstellungen. Das Audio selbst wird nur skaliert und im Panorama verteilt. Dadurch kann das Modell keine Artefakte „erfinden“, und seine Entscheidungen sind so lesbar wie ein Mischpult.

### 3 Schritt 1: Vom Audio zum Klangvektor – der VGGish-Encoder

Damit das Netz entscheiden kann, *was* auf einer Spur zu hören ist, muss das Audio in eine kompakte Beschreibung übersetzt werden. Dafür verwenden wir VGGish [2], ein Faltungsnetz,

das auf einer sehr großen Menge von Videotonspuren darauf trainiert wurde, Geräusch- und Musikklassen zu erkennen.

### Ablauf für eine Spur.

1. Die Spur wird von 44,1 kHz auf 16 kHz umgetastet (VGGish erwartet diese Rate).
2. Sie wird in Abschnitte von 0,96 s geschnitten; für jeden Abschnitt wird ein logarithmisches Mel-Spektrogramm berechnet, also eine Darstellung der Energie über Zeit und gehörangepassten Frequenzbändern.
3. Das Faltungsnetz bildet jeden Abschnitt auf einen Vektor mit 128 Zahlen ab.
4. Die Vektoren aller Abschnitte werden gemittelt. Ergebnis: *ein* Vektor  $e_i \in \mathbb{R}^{128}$  pro Spur.

**Warum eingefroren?** VGGish hat rund 72,1 Millionen Parameter. Mit unseren wenigen Trainingsdaten (Abschnitt 9) ließen sich diese nicht sinnvoll nachtrainieren – das Netz würde die Trainingsstücke auswendig lernen. Eingefroren liefert VGGish dagegen eine robuste, allgemeine Klangbeschreibung, und trainiert wird nur der kleine Entscheidungsteil.

**Was im Vektor steckt.** Vor allem die *Klangfarbe*: Eine Geigen-Spur und eine Posaunen-Spur landen an deutlich verschiedenen Stellen. Zum Teil auch der *Pegel*: Wird dieselbe Spur um 24 dB leiser gemacht, verschiebt sich der Vektor spürbar (Abstand 0,93 bei einer Vektorlänge von etwa 2,5). Das ist wichtig, denn ohne Pegelinformation könnte das Modell keinen passenden Gain wählen.

**Was verloren geht.** Durch die Mittelung über die Zeit weiß das Modell nicht, *wann* ein Instrument spielt oder wie sich die Dynamik entwickelt – passend zur Entscheidung für statische Einstellungen, aber eine klare Grenze (Abschnitt 13).

## 4 Schritt 2: Der Kontext – was spielt sonst noch mit?

Wie laut und wo eine Geige gemischt wird, hängt davon ab, was sonst im Stück passiert: Im Streichquartett ist sie Hauptstimme, in der Sinfonie eine von vielen. Deshalb bekommt jede Spur zusätzlich einen *Kontextvektor*, den Mittelwert über alle Spuren des Stücks:

$$c = \frac{\sum_{i=1}^N m_i e_i}{\sum_{i=1}^N m_i}. \quad (2)$$

**Wozu die Maske  $m_i$ ?** Im Training werden mehrere Stücke gleichzeitig verarbeitet (ein *Batch*). Weil Stücke unterschiedlich viele Spuren haben, werden kürzere Listen mit stummen Platzhalterspuren aufgefüllt. Die Maske sorgt dafür, dass diese Platzhalter weder in den Mittelwert noch später in den Mix eingehen.

### Zwei nützliche Eigenschaften.

- **Beliebige Spurzahl:** Ein Mittelwert funktioniert für 4 wie für 37 Spuren.
- **Reihenfolge egal:** Vertauscht man die Spuren, ändert sich  $c$  nicht, und jede Spur bekommt dieselbe Entscheidung. Das Modell ist *permutationsäquivalent* – die Dateireihenfolge spielt keine Rolle.

## 5 Schritt 3: Die Entscheidung – das MLP

Das mehrschichtige Perzeptron (MLP) ist der einzige Teil, der lernt. Es bekommt für jede Spur ihren eigenen Klangvektor und den Kontext, hintereinander gehängt zu einem Vektor mit 256 Zahlen, und gibt zwei Zahlen aus.

| Schicht                      | Form                  | Parameter |
|------------------------------|-----------------------|-----------|
| Eingabe $[e_i; c]$           | 256                   | –         |
| Linear + PReLU + Dropout 0,1 | $256 \rightarrow 256$ | 65 793    |
| Linear + PReLU + Dropout 0,1 | $256 \rightarrow 256$ | 65 793    |
| Linear                       | $256 \rightarrow 2$   | 514       |
| Summe                        |                       | 132 100   |

**Tabelle 2:** Architektur des MLP. PReLU ist eine Aktivierungsfunktion mit lernbarer Steigung im negativen Bereich; Dropout schaltet im Training zufällig 10 % der Neuronen ab und beugt so dem Auswendiglernen vor.

Die beiden Rohausgaben  $z_1, z_2$  werden in gültige Reglerstellungen umgerechnet:

$$g_i = \text{softplus}(z_1) = \ln(1 + e^{z_1}) \geq 0, \quad \theta_i = \frac{\pi}{2} \sigma(z_2) = \frac{\pi}{2} \cdot \frac{1}{1 + e^{-z_2}} \in \left[0, \frac{\pi}{2}\right]. \quad (3)$$

Softplus garantiert einen nicht-negativen Gain, die Sigmoid-Funktion  $\sigma$  einen Winkel zwischen ganz links und ganz rechts. Zu Beginn des Trainings liegen die Ausgaben nahe null, also  $\theta \approx \pi/4$ : Jede Spur startet in der Mitte.

**Geteilte Gewichte.** Für jede Spur wird *dasselbe* MLP verwendet. Das Modell lernt also keine Regel „Spur Nummer 3 nach links“, sondern „eine Spur, die *so* klingt, in einem Stück, das *so* klingt, gehört dorthin“. Nur deshalb funktioniert es auf Aufnahmen mit anderen Spurnamen und anderer Spurzahl.


## 6 Schritt 4: Anker – feste Positionen für das Hauptsystem

Bei den Mikrofonen des Hauptsystems ist die Stereoposition physikalisch vorgegeben: Das linke Tree-Mikrofon gehört nach links, das rechte nach rechts. Diese Spuren werden über ihren Dateinamen erkannt (z. B. \*\_L, \*\_C, \*\_R, \*\_RoomL) und bekommen einen festen Winkel: 0°, 45° bzw. 90°. Der vorhergesagte Winkel wird für sie verworfen; ihren *Gain* wählt das Modell aber weiterhin selbst.

Anker haben zwei Vorteile: Sie geben dem Stereobild eine eindeutige Orientierung (Abschnitt 8) und nehmen dem Modell Entscheidungen ab, die ohnehin feststehen. Wichtig in der Anwendung: Beim Mischen eines neuen Stücks muss dieselbe Ankerliste gelten wie im Training.

## 7 Schritt 5: Der Mixer – ein differenzierbares Pan-Gesetz

Der Mixer setzt Gleichung (1) um. Der Anteil einer Spur im linken und rechten Kanal ist  $g \cos \theta$  bzw.  $g \sin \theta$ . Weil  $\cos^2 \theta + \sin^2 \theta = 1$  gilt, bleibt die abgestrahlte *Leistung* einer Spur an jeder Panoramaposition gleich (*Constant-Power-Panning*): Ein Instrument wird beim Verschieben nicht lauter oder leiser. In der Mitte ( $\theta = 45^\circ$ ) erhält jeder Kanal den Faktor  $\cos 45^\circ \approx 0,707$ , also  $-3$  dB (Abbildung 2).



**Abbildung 2:** Das Constant-Power-Pan-Gesetz. Die Gesamtleistung einer Spur (grau gestrichelt) ist unabhängig von ihrer Position.

**Kernaussage.** Der Mixer ist die entscheidende Idee des Ansatzes. Weil er aus lauter differenzierbaren Operationen besteht (Multiplikationen, Kosinus, Sinus, Summen), lässt sich berechnen, wie sich der Fehler des fertigen Mixes ändert, wenn man einen Regler ein wenig verstellt. Das Modell braucht deshalb *keine* Beispiele für „richtige“ Reglerstellungen – es lernt allein aus Paaren von Einzelspuren und fertigem Mix. Diese Idee eines differenzierbaren Mischpults geht auf Steinmetz et al. [1] zurück; unser Mischpult ist bewusst auf Gain und Pan reduziert.

## 8 Schritt 6: Wie gut ist der Mix? – die Verlustfunktion

Die Verlustfunktion misst, wie weit der vorhergesagte Mix  $\hat{y}$  von der Referenz  $y$  entfernt ist. Ein direkter Vergleich der Wellenformen Sample für Sample wäre ungeeignet: Er reagiert extrem empfindlich auf kleinste Phasenunterschiede, die man nicht hört. Stattdessen vergleichen wir *Spektrogramme*, also die Energie über Zeit und Frequenz.

**Ein Spektrogramm-Vergleich.** Für ein Signal wird mit der Kurzzeit-Fouriertransformation (STFT, Hann-Fenster der Länge  $n$ , Schrittweite  $n/4$ ) das Betragsspektrogramm  $|X|$  berechnet. Zwei Maße werden addiert:

$$\mathcal{L}_{\text{SC}} = \frac{\| |Y| - |\hat{Y}| \|_F}{\| |Y| \|_F}, \quad (4)$$

$$\mathcal{L}_{\text{LM}} = \frac{1}{K} \left\| \log(|Y| + \varepsilon) - \log(|\hat{Y}| + \varepsilon) \right\|_1. \quad (5)$$

Die *Spectral Convergence*  $\mathcal{L}_{\text{SC}}$  misst die relative Abweichung und wird von den lauten Anteilen dominiert. Der *Log-Magnitude*-Term  $\mathcal{L}_{\text{LM}}$  vergleicht logarithmierte Beträge; er gewichtet leise Anteile stärker und liegt näher an der Lautheitswahrnehmung des Gehörs.  $\|\cdot\|_F$  ist die Frobenius-Norm,  $K$  die Anzahl der Spektrogramm-Einträge,  $\varepsilon = 10^{-8}$ .

**Mehrere Auflösungen.** Ein langes Fenster löst Frequenzen fein auf, aber Zeit grob – ein kurzes umgekehrt. Deshalb wird der Vergleich bei drei Fenstergrößen  $n \in \{512, 1024, 2048\}$  gerechnet und gemittelt (*Multi-Resolution-STFT-Verlust*, MR-STFT [3, 4]):

$$\mathcal{L}_{\text{MR}}(\hat{x}, x) = \frac{1}{3} \sum_{n \in \{512, 1024, 2048\}} \left( \mathcal{L}_{\text{SC}}^{(n)} + \mathcal{L}_{\text{LM}}^{(n)} \right). \quad (6)$$

**Vier Ansichten des Stereosignals.** Der Gesamtverlust vergleicht vier aus dem Stereosignal abgeleitete Signale:

$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{MR}}(\hat{y}_L + \hat{y}_R, y_L + y_R)}_{\text{Summe (Mitte)}} + \underbrace{\mathcal{L}_{\text{MR}}(\hat{y}_L - \hat{y}_R, y_L - y_R)}_{\text{Differenz (Breite)}} + \underbrace{\mathcal{L}_{\text{MR}}(\hat{y}_L, y_L)}_{\text{links}} + \underbrace{\mathcal{L}_{\text{MR}}(\hat{y}_R, y_R)}_{\text{rechts}}. \quad (7)$$

Summe und Differenz stammen aus [1]. Die beiden Kanalterme haben wir ergänzt, und sie sind für Orchester entscheidend:

**Das Spiegel-Problem.** Vertauscht man in einem Mix links und rechts, bleibt die Summe  $L + R$  gleich, und die Differenz  $L - R$  wechselt nur das Vorzeichen – ihr Betragsspektrum ist identisch. Ein Verlust, der nur Summe und Differenz vergleicht, kann einen Mix also nicht von seinem Spiegelbild unterscheiden. Für Pop-Musik, wo die Seitenwahl oft beliebig ist, ist das gewollt [1]. Im Orchester gibt es dagegen eine feste Sitzordnung. In unseren frühen Versuchen hat das Modell diese Blindheit ausgenutzt und fast alles auf eine Seite gelegt (Pegelunterschied links zu rechts bis 22,7 dB). Die Kanalterme in Gleichung (7) bestrafen Energie auf der falschen Seite und beheben dieses Kollabieren; die Anker (Schritt 4) wirken zusätzlich strukturell in dieselbe Richtung.

## 9 Schritt 7: Das Training

### 9.1 Daten

| Datensatz | Beschreibung                                                                                                                                                                                          | Umfang                         |
|-----------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------|
| Spheres   | Echte Aufnahmen mit echtem Tonmeister-Mix (Hauptsystem L/C/R, Raum-Paar, Spots). Die Mischungen sind exakt statische Gain/Pan-Summen ( $R^2 = 1,000$ ); je zwei Songs teilen dieselben Einstellungen. | 4 Songs, 2 Mischungen, 5,7 min |
| SynthSOD  | Synthetisch gerenderte Orchesterstücke, jedes Instrument einzeln pro Mikrofonposition (Close Mic ohne Übersprechen, Tree als Hauptsystem).                                                            | 576 Stücke, davon 64 genutzt   |
| Synthmix  | Unsere Neuberechnung der SynthSOD-Ziele: Spots nach einem festen Sitzplan im Panorama verteilt (plus $\pm 5^\circ$ Zufall), Gains zufällig. Die wahren Werte werden pro Stück gespeichert.            | 64 Stücke                      |


**Tabelle 3:** Trainingsdaten. Die Synthmix-Ziele machen die Genauigkeit der Positionen direkt messbar, weil die richtige Antwort bekannt ist.

Der Sitzplan von Synthmix folgt der üblichen Orchesteraufstellung aus Zuhörersicht (Violine 1  $15^\circ$ , Violine 2  $30^\circ$ , Viola  $55^\circ$ , Cello  $70^\circ$ , Kontrabass  $80^\circ$ , Holzbläser um die Mitte, Blech halbrechts). Die zurückgerechneten Einstellungen der beiden echten Spheres-Tonmeister bestätigen ihn weitgehend: Violine 1 bei  $9,5^\circ$  bis  $16^\circ$ , Viola bei  $57^\circ$  bis  $59^\circ$ , Horn bei  $30^\circ$  bis  $31^\circ$ .

### 9.2 Ablauf

- **Aufteilung nach Stücken:** 10% der Stücke (7 von 68) werden für die Validierung zurückgehalten – ganze Stücke, nicht einzelne Ausschnitte, damit das Modell dort wirklich Unbekanntes sieht.

- **Ausschnitte:** Pro Epoche werden 1 000 zufällige Ausschnitte von 5 s Länge gezogen; zur Validierung dienen feste 200 Ausschnitte.
- **Optimierung:** Adam [5] mit Lernrate  $3 \cdot 10^{-4}$ , Batchgröße 16. Verbessert sich der Validierungsverlust 20 Epochen lang nicht, wird die Lernrate halbiert.
- **Nur das MLP** wird optimiert; VGGish bleibt unverändert.
- **Rechenzeit:** Das Training lief auf einer Kaggle-GPU, etwa 2,5 min pro Epoche.



**Abbildung 3:** Verlustkurven des 200-Epochen-Laufs. Der beste Validierungsverlust wird in Epoche 121 erreicht; danach sinkt nur noch der Trainingsverlust (leichtes Overfitting).

### 9.3 Experiment: Die echten Mischungen stärker gewichten

Bei gleichverteilter Auswahl stammen nur etwa 7 % der Ausschnitte aus Spheres, dem einzigen Datensatz mit echten Tonmeister-Entscheidungen. In einem zweiten Lauf bekam Spheres deshalb 40 % der Ausschnitte, erweitert um zwei Datenaugmentierungen:

- **Pegelvariation:** Jede Spur wird beim Laden zufällig um bis zu  $\pm 6$  dB lauter oder leiser gemacht, das Ziel bleibt gleich. Der richtige Gain verschiebt sich damit um den Gegenwert – das Modell muss den Pegel aus dem Audio ablesen.
- **Spur-Dropout:** Zufällig weggelassene Spots werden mit ihrem exakten Anteil vom Ziel abgezogen. Aus zwei Mischungen entstehen so viele gültige Teilbesetzungen.


Alles andere – Aufteilung, Modell, Verlustfunktion, Synthmix-Ziele – blieb gleich. **Kein einziges Maß wurde besser** (Tabelle 4).

| Maß                                | 200-Epochen-Lauf | Spheres-Gewichtung |
|------------------------------------|------------------|--------------------|
| Pan-Fehler, unbekannte Stücke      | 5,4°             | 6,6°               |
| Pan-Fehler, Spheres (im Training)  | 7,9°             | 8,2°               |
| Gain-Fehler, Spheres (im Training) | 2,69 dB          | 2,89 dB            |
| Trainingsverlust am Ende           | <b>0,97</b>      | 1,63               |

**Tabelle 4:** Beide Läufe, jeweils mit dem Stand der letzten Epoche gemessen.

Aufschlussreich ist die Art des Scheiterns. Der Trainingsverlust blieb bei 1,63 stehen, obwohl die Lernrate schon stark reduziert war (Abbildung 4), und die Tschaikowsky-Pegel blieben beim Fehler eines konstanten Tipps – *obwohl* diese Stücke im Training waren, mit sechsfachem Gewicht. Das Modell lernt die zwei echten Mischungen also nicht auswendig, es kann sie überhaupt nicht nachbilden.

**Kernaussage.** Der Engpass ist der Pegel, nicht die Datenmenge. Ein über die Zeit gemittelt VGGish-Embedding und ein Verlust, der nur Betragsspektren vergleicht, geben dem MLP zu wenig Information über den Pegel einer Spur. Die Pegelvariation hat die Aufgabe zusätzlich erschwert, ohne die nötige Information zu liefern.



**Abbildung 4:** Links der 200-Epochen-Lauf (bestes Modell), rechts der Lauf mit Spheres-Gewichtung. Rechts liegen Trainings- und Validierungskurve am Ende übereinander: Das ist kein Overfitting, sondern Underfitting.

## 10 Schritt 8: Anwendung auf ein neues Stück

Nach dem Training wird ein neues Stück so gemischt:

1. Alle Spuren werden geladen; Spuren des Hauptsystems erhalten ihre Anker-Winkel.
2. VGGish beschreibt jede Spur über ihre *gesamte* Länge (Mittelwert über alle 0,96 s-Abschnitte des Stücks).
3. Das MLP liefert einmal Gain und Pan pro Spur.
4. Der Mixer wendet diese festen Einstellungen auf das ganze Stück an.

Das Ergebnis ist ein vollständiger Stereomix und zugleich eine lesbare Mischpult-Einstellung (Abbildung 5).

## 11 Was das Modell kann – Ergebnisse im Überblick


**Positionen auf unbekannten Stücken (Synthmix-Validierung).** Gemessen auf den 7 zurückgehaltenen Stücken mit bekannter Aufstellung, 32 Spots:

| Maß                     | 60-Epochen-Lauf | 200-Epochen-Lauf | Alles in die Mitte | Bestmöglich    |
|-------------------------|-----------------|------------------|--------------------|----------------|
| Pan-Fehler (Mittel)     | 22,4°           | 5,8°             | 17,1°              | 2,5°           |
| Stereobalance $ L - R $ | 1,79 dB         | 1,29 dB          | –                  | 1,39 dB (Ziel) |

**Tabelle 5:** Die Untergrenze von 2,5° ergibt sich aus dem  $\pm 5^\circ$ -Zufall im Sitzplan, der aus dem Audio grundsätzlich nicht vorhersagbar ist.

Das Modell reproduziert die Sitzordnung monoton (Violine 1 links bis Kontrabass rechts), mit einer leichten Stauchung zur Mitte: Äußere Instrumente landen etwas zu weit innen.

**Pegel werden kaum gelernt.** Der Gain-Fehler von 1,37 dB auf den Validierungsstücken ist nicht besser als ein konstanter Pegel für alle Spuren (1,28 dB). Das ist kein Versäumnis des



**Abbildung 5:** Vom Modell gewählte Einstellungen für ein zurückgehaltenes Stück (Sinfonie, 11 Spuren): oben die Panoramaposition, darunter der Fader. Die Spuren Tree\_L und Tree\_R (Hauptsystem) sind Anker.

Modells: Die Synthmix-Gains werden unabhängig vom Klang gewürfelt und sind aus dem Audio grundsätzlich nicht vorhersagbar. Echte Pegelentscheidungen stehen nur in Spheres.

**Einstellungen echter Tonmeister (Spheres).** Gegen die zurückgerechneten Werte der zwei echten Mischungen erreicht das Modell einen Pan-Fehler von  $7,9^\circ$  (Mitte-Tipp:  $16,3^\circ$ ) und einen Gain-Fehler von 2,69 dB (konstanter Pegel: 5,15 dB). Beim Pan ist das deutlich besser als der Baseline-Tipp, beim Gain nur etwa halb so gut wie er. Achtung: Spheres war im Training, dies ist also keine Messung auf Unbekanntem – eine zurückgehaltene echte Mischung gibt es im Projekt nicht.

**Zurückgehaltene echte Mischung.** Im Lauf aus Abschnitt 12.1 landete eine der Spheres-Mischungen durch die Zufallsziehung in der Bewertung – die erste echte Mischung, die das Modell nie gesehen hat. Pan-Fehler  $8,77^\circ$  (Mitte-Tipp  $14,18^\circ$ ), Gain-Fehler 6,29 dB (konstanter Pegel 4,92 dB).

**Echte Konzertaufnahme (Wuppertal, 33–37 Spuren).** Eine eigene Konzertaufnahme, weit außerhalb der Trainingsverteilung: 33–37 Spuren statt 4–22, Stimmgruppen teils doppelt mikrofoniert, und alle Stützen mit Übersprechen. Bewertet wurde durch Hören, denn eine Referenzmischung gibt es nicht. In einem lyrischen Ausschnitt ordnet das Modell die Streicher korrekt von links nach rechts (Abbildung 6); in dichten Passagen staucht es fast alle Spots auf  $45^\circ$  bis  $60^\circ$  zusammen und wählt nahezu einheitliche Pegel.

## 12 Eignen sich eigene Aufnahmen als zusätzliches Trainingsmaterial?

Das Modell soll weiterhin allein aus fertigen Mischungen lernen. Damit hängt alles an einer Frage: Gibt es zu einer eigenen Aufnahme ein *Ziel*, das ein statischer Gain/Pan-Mix überhaupt



- **SUMME ist ein echtes Ziel.** In den beiden Ausschnitten mit gestützten Solisten liegt die Grenze bei 0,70 bzw. 0,74, deutlich unter dem heutigen Validierungsverlust von 1,40, und die Stützen tragen 10 % bis 12 % der Energie.
- **Aber nur in Teilen des Konzerts.** In Harfen- und Tutti-Ausschnitt steigt die Grenze auf 2,2 bis 2,6 und der Anteil der Stützen fällt auf 1 % bis 2 %. Dort dominieren Reglerfahrten, Hall und Klangbearbeitung – alles, was ein statisches Modell nicht abbilden kann. Training auf solchen Ausschnitten hieße, Rauschen zu lernen.

## 12.1 Das Konzert im Training: Der Verlust täuscht

Wir haben es ausprobiert. Aus dem Konzert wurden 124 Fenster von 30 s geprüft; 11 waren zu leise (Applaus, Pausen), 80 lagen unter der Güteschwelle, 33 blieben übrig – 16,5 min Material mit  $R^2$  zwischen 0,95 und 1,00, alle aus den ersten 63 Konzertminuten. Diese kamen zu den 68 bisherigen Stücken dazu, sonst wurde nichts geändert. Ein zusammenhängender Block von Minute 44 bis 63 wurde zurückgehalten; benachbarte Fenster klingen fast gleich, eine zufällige Aufteilung würde Trainingsmaterial in die Bewertung durchsickern lassen.

| Zurückgehalten von | Maß                                            | bisheriges Modell | Konzert-Modell |
|--------------------|------------------------------------------------|-------------------|----------------|
| beiden Läufen      | Pan-Fehler (Streichquartett)                   | 4,20°             | 6,53°          |
| beiden Läufen      | Verlust (Streichquartett)                      | <b>1,26</b>       | 2,68           |
| beiden Läufen      | Verlust (9 Konzertfenster)                     | 18,91             | <b>3,27</b>    |
| beiden Läufen      | Pan-Fehler (Konzert; Mitte 28,6°)              | 29,20°            | 28,65°         |
| beiden Läufen      | Gain-Fehler (Konzert; konstant 8,70 dB)        | 8,62 dB           | 9,46 dB        |
| nur neuem Lauf     | Gain-Fehler (echte Mischung; konstant 4,92 dB) | –                 | 6,29 dB        |

**Tabelle 6:** Gruppenweise gemessen, weil der Validierungsverlust der beiden Läufe nicht vergleichbar ist: Der Bewertungssatz hat sich durch die neuen Fenster verändert.

Auf Konzertmaterial fällt der Verlust um das Sechsfache – und trotzdem hat das Modell das Mischen nicht gelernt. Seine Positionen treffen den Mitte-Tipp auf ein halbes Grad genau, seine Pegel sind schlechter als ein einziger konstanter Wert für alle Spuren. Gelernt hat es das grobe *Pegelregime* einer Aufnahme mit 33–37 Spuren, also wie weit alles heruntergezogen werden muss. Das belohnt der Verlust stark, denn es betrifft jede Spur gleichzeitig; das bisherige Modell kannte höchstens 22 Spuren und lag hier weit daneben.

Gleichzeitig hat der Zugewinn anderswo gekostet: Auf einem Stück, das *beide* Läufe zurückgehalten haben, stieg der Pan-Fehler von 4,20° auf 6,53° und der Verlust verdoppelte sich.

**Kernaussage.** Ein einzelnes Konzert ist eine Mischphilosophie, ein Saal, eine Besetzung. 16,5 min davon verschieben das Modell in Richtung dieser einen Aufnahme, statt ihm eine übertragbare Regel beizubringen. Der größte Nutzen der eigenen Aufnahme liegt deshalb in der *Bewertung*: Sie liefert die erste zurückgehaltene echte Mischung des Projekts. Und sie zeigt, wie wenig der Verlustwert allein aussagt.

## 13 Grenzen und offene Punkte

- **Der Pegel ist der Engpass.** Die Synthmix-Gains sind gewürfelt und damit grundsätzlich nicht lernbar; echte Pegelentscheidungen enthält nur Spheres, und dort unterscheiden sie sich stark zwischen den Stücken (bei Mozart stehen die Streicher vorn, bei Tschaikowsky die Holzbläser). Das Experiment in Abschnitt 9.3 zeigt, dass mehr Gewicht auf diesen Daten nicht genügt: Das Modell bildet die echten Pegel selbst dann nicht nach, wenn es auf ihnen trainiert. Ein gemitteltes Embedding und ein Verlust auf Betragsspektren sind dafür zu grobe Werkzeuge.

- **Stauchung zur Mitte.** Bei Unsicherheit ist die Mitte der sicherste Tipp; das Modell nutzt die Stereobreite nicht voll aus.
- **Abstand zu echten Aufnahmen.** Die synthetischen Spots haben kein Übersprechen, echte schon; im Training gab es 4–22 Spuren, in Wuppertal 33–37, teils mit zwei Mikrofonen pro Stimmgruppe.
- **Statische Einstellungen.** Keine Pegelautomation, kein EQ, kein Hall, keine Laufzeitkorrektur zwischen Spot und Hauptsystem.
- **Wenig echte Referenzen.** Zwei echte Mischungen reichen nicht, um stückabhängige Pegelentscheidungen zu lernen. Im Lauf aus Abschnitt 12.1 wurde erstmals eine echte Mischung zurückgehalten (Tschaikowsky): Dort liegt der Pan-Fehler bei  $8,77^\circ$  gegenüber  $14,18^\circ$  für den Mitte-Tipp, der Gain-Fehler aber bei 6,29 dB und damit *schlechter* als ein konstanter Pegel (4,92 dB). Positionen überträgt das Modell also auf unbekannte echte Mischungen, Pegel nicht.
- **Der Verlustwert ist ein schlechter Ratgeber.** Er verbesserte sich auf Konzertmaterial um das Sechsfache, während die Reglerentscheidungen auf dem Niveau trivialer Vergleichswerte blieben (Abschnitt 12.1). Aussagen über die Qualität einer Mischung sollten deshalb immer an Grad und Dezibel gemessen werden, nicht am Verlust.

## 14 Vorschlag: Vom Dokument zum Paper

| Paper-Abschnitt    | Inhalt aus diesem Dokument                                                                                                                                 |
|--------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Einleitung         | Abschnitt 1: Aufgabe, Hauptsystem vs. Spots, Motivation für statische Gain/Pan-Entscheidungen.                                                             |
| Verwandte Arbeiten | Differenzierbares Mischpult [1], VGGish [2], MR-STFT-Verlust [3, 4]; L/R-Invarianz bei Steinmetz vs. feste Orchesteraufstellung.                           |
| Methode            | Abschnitte 3–7 und Abbildung 1; Gleichungen (1), (2), (7).                                                                                                 |
| Daten              | Abschnitt 9: Spheres, SynthSOD, Synthmix; Sitzplan und dessen Bestätigung durch echte Tonmeister.                                                          |
| Experimente        | Pan-Kollaps und dessen Behebung (Verlust mit Kanaltermen), 200-Epochen-Lauf, Spheres-Gewichtung (Abschnitt 9.3), Eignung eigener Aufnahmen (Abschnitt 12). |
| Ergebnisse         | Pan-Fehler mit Baselines und Rauschgrenze; Spheres; Wuppertal als qualitative Fallstudie.                                                                  |
| Diskussion         | Abschnitt 13; besonders: Verlust vs. tatsächliche Reglerentscheidungen, und warum eine einzelne Aufnahme das Modell verschiebt statt es zu verbessern.     |

**Noch zu ergänzen.** Quellenangaben für den Spheres- und den SynthSOD-Datensatz. Beide sind hier bewusst nicht zitiert: Die genauen Veröffentlichungen liegen uns nicht vor, und geratene Literaturangaben wären schlimmer als eine offene Lücke. Sie gehören in Abschnitt 9 und ins Literaturverzeichnis, bevor das Paper eingereicht wird.

## Literatur

- [1] C. J. Steinmetz, J. Pons, S. Pascual, J. Serrà: *Automatic multitrack mixing with a differentiable mixing console of neural audio effects*. Proc. IEEE ICASSP, 2021.
- [2] S. Hershey et al.: *CNN architectures for large-scale audio classification*. Proc. IEEE ICASSP, 2017.

- [3] R. Yamamoto, E. Song, J.-M. Kim: *Parallel WaveGAN: A fast waveform generation model based on generative adversarial networks with multi-resolution spectrogram*. Proc. IEEE ICASSP, 2020.
- [4] S. Ö. Arık, H. Jun, G. Diamos: *Fast spectrogram inversion using multi-head convolutional neural networks*. IEEE Signal Processing Letters 26(1), 2019.
- [5] D. P. Kingma, J. Ba: *Adam: A method for stochastic optimization*. Proc. ICLR, 2015.